

扩散 / 流 / 漂移：四种生成模型的统一理解

DDPM · Score-SDE · Flow Matching · Drifting Models

本汇报围绕四篇论文：DDPM (Ho et al., 2020)、Score-Based Generative Modeling through SDE (Song et al., 2020)、Flow Matching for Generative Modeling (Lipman et al., 2022)、Generative Modeling via Drifting (2026)。重点不在于堆叠公式或罗列指标，而在于把四篇论文放进同一条主线上，看清它们各自突破了前作的什么限制、为什么这样设计、以及哪些细节是只有真正读懂以后才会注意到的。

一、四篇论文在做同一件事

把四篇论文剥到骨头，它们都在解同一个问题：

学一个映射 f ，使先验分布 $p_0 = N(0, I)$ 的推前分布 $f_{\#}p_0$ 逼近未知数据分布 p_{data} 。

直接的「一步映射 $N(0, I) \rightarrow \text{图像}$ 」非常难学（GAN 走对抗路、VAE 走 ELBO 都有其代价）。四篇论文一致地选择了另一种思路：把这个困难映射分解成一串「小步」——从噪声到数据之间构造一条概率路径，让神经网络每次只学一阶一小段，再在采样时沿这条路径迭代演化样本。

因此这四篇其实是同一个数学骨架的四个版本，差别只在三件事上：

- 路径用什么数学对象描述：离散马尔可夫链 $\rightarrow$ 连续 SDE $\rightarrow$ 任意概率路径的 ODE 流 $\rightarrow$ 训练时 SGD 演化的推前分布。
- 神经网络被训练来预测什么：噪声 ϵ 、分数 $\text{grad} \log p$ 、向量场 v_t 、还是漂移场 V 。
- 采样怎么跑：1000 步祖先采样 $\rightarrow$ PC/ODE 求解器 $\rightarrow$ 数十步 ODE $\rightarrow$ 一步前向。

沿着这三条轴看过去，后一篇总是把前一篇当作特例。

二、DDPM：把扩散做成可规模化训练的离散链

2.1 推导骨架

前向过程是固定方差的马尔可夫链（无可学习参数），用 $\beta_1, \dots, \beta_T$ 线性调度（ $T=1000$ ， β 从 $1e-4$ 到 0.02 ）。真正让训练可行的，是闭式边际：

$$q(x_t | x_0) = N(\sqrt{A_t} x_0, (1-A_t) I), \quad A_t = \prod_{s \leq t} (1 - \beta_s).$$

这个闭式让训练样本 $x_t = \sqrt{A_t} x_0 + \sqrt{1-A_t} \epsilon$ 可以一次采出，不需要逐步跑链。这是扩散模型能 scale 的工程前提。

2.2 真正的设计突破： ϵ -参数化

论文原本可以让人网路预测均值 μ_t ，也能反向还原 x_0 。但作者发现：把前向后验展开， μ_t 中 x_0 的项可以等价替换成 ϵ ，于是 μ_θ 直接写成：

$$\mu_\theta(x_t, t) = (1/\sqrt{\alpha_t}) [x_t - \beta_t / \sqrt{1-A_t} \cdot \epsilon_\theta(x_t, t)].$$

这个看似只是变量替换，但带来了三件事：

- 目标函数从加权变分下界塌缩成 $\|\epsilon - \epsilon_\theta(x_t, t)\|^2$ ，无权重、稳定、易实现。
- 与多噪声尺度的去噪分数匹配等价： $s_\theta = -\epsilon_\theta / \sqrt{1-A_t}$ 。这为后面 Score-SDE 埋伏笔。
- 采样过程类似退火 Langevin 动力学，统一了「扩散」与「分数匹配」两条原本独立的路线。

一个容易被忽视的权衡：简化目标在

log-likelihood

上变差，但样本质量反而更好。原因——丢权重后，小

t （噪声极小、去噪极易）的损失项被相对降权，网络把容量让给「更难的大噪声去噪」。这是「加权变分下界

VS

简化目标」的内在张力，也是论文反复强调「性能差异源于重新加权，而非目标本身」的地方。

2.3 我从 DDPM 读到的关键事实

- 反向方差 Σ_{θ}
实测不该学——学习它会让训练不稳定、质量更差。这是工程上非常重要的反直觉结论。
- σ_t^2 有两种等价选择： β_t 与 $\beta_{alt}=(1-A_{t-1})/(1-A_t)\cdot\beta_t$ 。前者对 $x_0 \sim N(0, I)$ 最优，后者对确定性 x_0 最优；工程上可以任选。
- $T=1000$ 与「同 PixelCNN++ 风格 U-Net + 组归一化 + 16×16 自注意力 + 正弦时间嵌入」的组合不是任意，而是与 prior 工作沿用的网络对齐，保证 NFE 可比。

三、Score-SDE：把链推广到连续时间，把采样交给求解器

3.1 这个推广的真正价值

表面上是 $T \rightarrow \infty$ 的连续化。但真正重要的不是「连续」，而是两件事：

- DDPM 与 SMLD 是同一个 SDE 的两个不同离散化——这是把两类方法合并到一个框架下的关键洞察。DDPM = VP SDE 的离散化；SMLD = VE SDE 的离散化。
- 反向 SDE 由 Anderson (1982) 给出，只依赖边缘分数 $\text{grad log } p_t$ 。这意味着掌握了分数，就把「能用任意数值求解器自由采样」这件事一次性解锁。

3.2 三种 SDE 与一个关键 ODE

前向 SDE: $dx = f(x,t) dt + g(t) dw$ 。三种实例：

- VE: $dx = \text{sqrt}(d[\sigma^2(t)]/dt) dw$ ← SMLD 的连续化
- VP: $dx = -\frac{1}{2} \beta(t) x dt + \text{sqrt}(\beta(t)) dw$ ← DDPM 的连续化
- sub-VP: + 附加 $(1 - e^{-2\int \beta})$ 因子 ← 本文新提，似然最好

由于三者都有仿射漂移，转移核

$$p_{\{0t\}}(x(t)|x(0))$$

都是高斯、闭式可算。这让连续时间的分数匹配损失可以直接逐样本无偏估计。

训练目标（连续时间版）是 DDPM 简化目标的自然推广：

$$L = E_t [\lambda(t) \cdot E_{\{x_0, x_t|x_0\}} \| s_{\theta}(x_t, t) - \text{grad log } p_{\{0t\}}(x_t|x_0) \|^2]$$

权重 $\lambda(t)$ 通常取 $1/E\|\text{grad log } p_{\{0t\}}\|^2$ ，相当于按噪声尺度自适应归一，起到与 DDPM「丢权重后小 t 自动降权」类似的效果。

3.3 采样：PC 与概率流 ODE

这一节是

Score-SDE

真正改变了下游使用体验的地方。给定训练好的分数模型，有三种采样路线，它们各对应一种「利用额外信息」的程度：

- 通用数值求解器 (Euler-Maruyama / 随机 Runge-Kutta)：纯黑盒。祖先采样是其中一种特殊离散化；反向扩散采样器以与前向相同方式离

散，对新 SDE 推导友好。实测反向扩散略优于祖先采样。

- Predictor-Corrector (PC): 在 SDE 求解器 (Predictor) 每步后接一段基于分数的 MCMC (Corrector) 校正边缘分布。它把 SMLD 和 DDPM 的原始采样统一为两个特例。实测同 NFE 下 PC 优于仅 Predictor、远优于仅 Corrector。
- 概率流 ODE: $dx = [f - \frac{1}{2} g^2 \text{grad} \log p_t] dt$ 。与原 SDE 共享边缘密度 $\{p_t\}$ ，但完全确定性。这是 [Paper](#) [4](#) 真正解锁的能力——通过瞬时变量变换公式可算精确似然、用黑盒 ODE 求解器自适应步长把 NFE 砍掉 90%+、给出唯一可识别的编码。

一个最常被读错的细节：反向 SDE 中的系数是 g^2 ，而概率流 ODE 中是 $\frac{1}{2} g^2$ 。差一个 $1/2$ 是 Fokker-Planck 平衡布朗运动的产物；写错它会在工程上『差一点』而难以排查。

3.4 条件 SDE：留给下游多任务成像的核心接口

条件反向 SDE 只需在分数上加一阶「似然项」：

$$dx = \{f - g^2 [\text{grad} \log p_t(x) + \text{grad} \log p_t(y|x)]\} dt + g dw$$

这意味着同一个无条件分数模型可以处理：类条件生成（训一个时间依赖分类器）、inpainting（已知子集 $\Omega(y)$ 的条件）、colorization（解耦后再 inpaint）等逆问题，都无需重训主模型。这与本项目「多任务成像」需求天然契合——这是后面 Score-SDE 比 DDPM 更值得作为基线的真实原因。

四、Flow Matching：把扩散推广成任意概率路径，让 OT 把轨迹拉直

4.1 突破口：CFM 与 FM 梯度等价

CNF 训练长期被「需要昂贵的 ODE 仿真」卡住。FM 给出的破局点是 Theorem 2：

$$\text{grad}_\theta L_{\text{FM}}(\theta) = \text{grad}_\theta L_{\text{CFM}}(\theta),$$

$$L_{\text{CFM}} = E_{\{t, q(x_1), p_t(x|x_1)\}} \|v_t(x) - u_t(x|x_1)\|^2.$$

直觉：不需要知道边际概率路径 $p_t(x)$ 与边际向量场 $u_t(x)$ （它们没有闭式），只需要逐样本构造条件路径 $p_t(x|x_1)$ 与条件向量场 $u_t(x|x_1)$ ，并回归它即可——这与 DDPM / Score-SDE 用「条件去噪分数匹配」绕开边际密度的策略是同构的，但 FM 抽得更彻底：直接回归向量场，不再绕「分数 - 二阶导」那一层。

4.2 高斯条件路径与 OT 选择

FM 考虑一族高斯条件路径 $p_t(x|x_1) = N(\mu_t(x_1), \sigma_t(x_1)^2)$ 。令 $\mu_t = t \cdot x_1$ 、 $\sigma_t = 1 - (1 - \sigma_{\min}) \cdot t$ ，得到最优传输位移插值：

$$\psi_t(x) = (1 - (1 - \sigma_{\min})t)x + t x_1,$$

$$u_t(x|x_1) = [x_1 - (1 - \sigma_{\min})x] / [1 - (1 - \sigma_{\min})t].$$

这一步的真正意义是「轨迹变直」——粒子沿直线匀速运动，向量场方向不随时间反转、不弯曲。对照扩散路径：分数向量场在 t 接近 1 时会显著回撤，方向会变；这导致训练易抖动、采样需要更多步。

一个常被混淆的点：这里的『OT』是条件路径上的 OT，不是边际路径上的 OT。条件轨迹是直线 $\neq$ 边际轨迹是 OT 映射。读 FM 时要分清这一层。

4.3 在 ImageNet 上的关键收益

- 训练更稳：扩散路径上 FM 训练也比 DSM 训练更鲁棒——这说明「梯度等价」之外，FM 在数值上还有边际稳定性收益。
- NFE 显著下降：OT 路径下可以在 10-20 步内得到可用样本；dopri5 自适应可继续压缩。
- 似然与质量同时居前：ImageNet-128 上 2.90 BPD / 20.9 FID；既优于扩散方法也优于传统 CNF。

五、Drifting：把迭代搬到训练时，让一次前向就是一次完整生成

5.1 思路反转

前三篇都在推理时迭代演化样本。Drifting 把演化从推理端搬到训练端：网络训练本身就是 SGD 迭代，每次参数更新让固定噪声 ϵ 对应的样本 $x=f_{\theta}(\epsilon)$ 产生一位移，这个位移即『漂移』。当 f_{θ} 收敛到 p_{data} 时漂移消失 $\rightarrow$ 训练收敛后一步前向就是采样。这就是 1-NFE 生成的来源。

5.2 反对称：让 V 在 $p=q$ 时严格归零

命题 3.1: 若 $V_{\{p,q\}}(x) = -V_{\{q,p\}}(x)$, 则 $q = p \implies V = 0$ 。这是论文里最短但最关键的事实——它保证『匹配后停止演化』，让 SGD 训练不会在已经匹配好的地方持续瞎动。

具体构造采用类 mean-shift 的吸引-排斥形式：

$$\begin{aligned} V_{\{p,q\}}(x) &= V_p^+(x) - V_q^-(x), \\ V_p^+(x) &= (1/Z_p) E_{y \sim p} [k(x, y)(y - x)], \\ V_q^-(x) &= (1/Z_q) E_{y \sim q} [k(x, y)(y - x)]. \end{aligned}$$

直观：每个生成样本被数据样本『吸引』、被生成样本自身『排斥』——这是用核密度估计直接把样本推向数据模版去噪思路。二者在 $p=q$ 时严格抵消，从而反对称自然成立。论文在玩具实验里反复证明：一旦破坏反对称（只吸引、只排斥、或不对称放大），FID 从 8 涨到 41-177。

5.3 损失与 stopgrad：工程上必须看对的细节

$$L = E_{\epsilon} [\| f_{\theta}(\epsilon) - \text{stopgrad}(f_{\theta}(\epsilon) + V_{\{p,q_{\theta}\}}(f_{\theta}(\epsilon))) \|^2]$$

等价于 $E[\|V\|^2]$ ，但 V 依赖 q_{θ} 不能直接反传，于是把『漂移后的位置』作为冻结目标。stopgrad 的位置非常关键——如果对 $+V$ 这个目标也求导，会塌缩到把输出推向自己，模型什么也不学。这是工程上极易出错的地方。

5.4 特征空间漂移与 CFG 的训练时化

高维图像上直接做漂移效果差，关键是把损失放到自监督编码器（MoCo / SimCLR / latent-MAE）的多尺度特征空间里。特征提取器只在训练时用，推理时仍然是单次前向。这与感知损失无关：感知损失要配对， V 用 $+V$ 做冻结目标，本质上匹配 $\varphi_{\#q}$ 与 $\varphi_{\#p}$ 。

CFG 也被改造成训练时行为——通过在负样本中混入无条件数据分布：

$$q(\cdot|c) = (1-\gamma) q_{\theta}(\cdot|c) + \gamma p_{\text{data}}(\cdot|\text{无条件}), \quad \text{则} \quad q_{\theta}(\cdot|c) = \alpha p_{\text{data}}(\cdot|c) - (\alpha-1) p_{\text{data}}(\cdot|\text{无条件}).$$

训练时随机采 α 作为条件，推理时自由指定——这是与传统 CFG 的本质区别：传统 CFG 在推理时外推条件/无条件分数，Drifting 在训练时就构造好了等价的目标分布。

5.5 最终结果与意义

- ImageNet 256×256: 潜空间 FID 1.54、像素空间 FID 1.61, 1 步生成; 无需从教师蒸馏。
 - 机器人控制: 一步 Drifting Policy 替换多步 Diffusion Policy, 多个单阶段/多阶段任务成功率持平或更高。
 -
- 意义: 把「一步生成」从「蒸馏出来的近似」变成「原生训练目标」——这是新的研究方向, 而非工程加速。

六、四篇论文的统一对照

6.1 演进维度横向对比

维度	DDPM / Score-SDE / Flow Matching / Drifting
路径对象	离散马尔可夫链 / 连续 SDE / 任意概率路径 ODE 流 / 训练时推前分布演化
网络预测量	噪声 ϵ / 分数 $\text{grad log } p$ / 向量场 v_t / 漂移场 V
训练目标	$\ \epsilon - \epsilon_\theta\ ^2$ 加权去噪 / 分数匹配 / 向量场回归 / $E\ V\ ^2 + \text{stopgrad}$
采样方式	1000 步祖先 / PC + 概率流 ODE / 数十步 ODE / 1 步前向
似然计算	ELBO 近似 / 精确 (瞬时变量变换) / 精确 (神经 ODE) / 无
条件机制	类条件 ϵ 网络 / 条件反向 SDE (统一接口) / 条件路径 / 训练时 CFG 负样本
相对位置	起点 / 通用框架 / 任意路径化 / 反转迭代位置

6.2 几个只有真读懂才不会记错的点

- ϵ 与 score 的关系: $s_\theta = -\epsilon_\theta / \sqrt{1-A_t}$ 。负号与分母都不能丢; 丢掉就变成去了相反方向。
- 反向 SDE 与概率流 ODE 的系数差: g^2 vs $\frac{1}{2}g^2$ 。差一个 1/2 来自 Fokker-Planck 中的二阶项折半。
- DDPM 的「丢权重 = 简化目标」看似损失 log-likelihood, 但样本质量反而更好——因为小 t 项被相对降权, 让模型聚焦在更难的大 t 去噪。
- Flow Matching 的『OT』是条件向量场上的 OT (粒子直线匀速), 不是边际分布之间的 OT。混淆会让对算法性质的理解出错。
- Drifting 的 stopgrad 必须作用于 $(x + V)$ 整体而非 x 自己, 否则梯度塌缩到 0, 模型什么也学不到——这是工程实现里最隐蔽的坑。
- Drifting 的「漂移场 $= 0 \implies p = q$ 」并非对任意 V 成立; 只有在论文给出的核化、反对称、且非退化假设下才成立。所以反对称不是美学要求, 是平衡条件的数学必需。

6.3 各自在「什么时候选」的判断

- DDPM: 作为熟悉扩散的入口、对基线最熟悉时的稳健选型。
-
- Score-SDE: 要在统一接口下做多种条件/逆问题 (inpainting、colorization、SR) ——它给出的条件反向 SDE 是四篇里最成熟的框架。
- Flow Matching + OT: 在大规模高质量任务上要尽量少 NFE、又不损失似然时。现在做大规模图像生成默认从这里起步。
- Drifting: 极致推理速度、或落地部署必须 1-NFE

的场景。代价是训练机制更复杂，理论平衡条件尚不完全严格。

七、我的整体理解

这四篇不是四条独立路线，而是同一条主线在三个维度上的渐进推进：

- 数学对象从离散链 $\rightarrow$ SDE $\rightarrow$ 任意概率路径 ODE $\rightarrow$ 训练时推前分布演化；
- 网络要预测的量从 $\varepsilon \rightarrow \text{grad log } p \rightarrow v_t \rightarrow V$ ，越来越『靠近』直接回归路径几何本身；
- 采样从 1000 步 $\rightarrow$ 数十步 $\rightarrow$ 1 步。

每后一篇都把前一篇当作特例：DDPM = VP SDE 的祖先采样离散化 (Score-SDE)；扩散路径 = FM 在特殊高斯路径上的实例 (Flow Matching)；前三篇全部都是「推理时迭代」，Drifting 把这条轴翻向「训练时演化」。把这一层关系看清楚，四篇就不再是四个孤立的方法，而是同一个理论体系在『采样成本』上的连续推进。

对我自己而言，做「多任务成像」时的实际判断会是：

- 先把 Score-SDE 的条件反向 SDE 当成框架原型——它在数学上最成熟、条件扩展最干净。
- 在大规模训练时切换到 Flow Matching + OT 路径，享受训练稳定与 NFE 下降的红利。
- 在落地到必须实时一步出图的环节，尝试把 Drifting 当作下一步目标；但要小心 stopgrad 与反对称这些工程坑。

真正读懂这四篇的标志，不是能复述公式，而是能在一张白纸上画出一条主线、指出每篇在哪条轴上完成了什么跃迁、以及每个跃迁背后牺牲了什么——这三件事一起说清楚，才算把这四篇读到了肌肉记忆里。