

组会论文汇报 · 2026-09-20

高分辨率图像合成 与潜空间扩散模型


High-Resolution Image Synthesis with Latent Diffusion Models

Robin Rombach*, Andreas Blattmann*, Dominik Lorenz, Patrick Esser, Björn Ommer

LMU Munich & Heidelberg University · Runway ML · CVPR 2022

arXiv 2112.10752 · Stable Diffusion 底座论文

汇报人：潘耀辉



论文图 3: LDM 条件注入机制 (拼接 / cross-attention)

汇报大纲

01

扩散模型基础

生成模型全景 · 前向/反向逐公式 · ELBO 推导 · U-Net

03

条件机制与引导

拼接 / Cross-Attention (含实例) / CFG

05

对我们课题的启发

条件 LDM 原型的三个设计决策

02

方法：两阶段潜空间扩散

自编码器损失逐项 · 潜空间 DDPM 逐符号对照

04

实验结果

压缩率消融与五类任务的定量结论

06

总结与讨论

要点回顾 + 两个待讨论问题

01

扩散模型基础与动机


逐公式推导：前向、反向、ELBO、U-Net —— 再看 LDM 为什么、怎么搬进潜空间

生成模型全景：扩散模型的崛起




- GAN（对抗）与 VAE（变分）之后，2020 年 DDPM 把「逐步去噪」变成图像生成的第三条主线
- 扩散训练稳定、多样性好、引导机制灵活 → 迅速成为 AIGC 的主流骨干
- 2022 年 Stable Diffusion 出圈——其底座架构正是本次汇报的 LDM 论文（CVPR 2022）

扩散模型 = 前向加噪 + 反向去噪



前向过程 q : 加噪 —— 固定、无参数、逐步趋近标准高斯



反向过程 p_θ : 去噪 —— 神经网络学习; 采样 (生成) = 反复执行去噪

- 两个过程都是马尔可夫链: 当前步只依赖上一步
- 训练: 给定 x_0 , 学习每一步该去掉多少噪声
- 采样: 从纯噪声 x_T 出发, 一步步去噪得到图像 x_0

先把六个符号摆齐


符号	含义	一句话理解
x_0	干净图像	我们真正想生成的东西
x_t	加了 t 步噪声的图像	t 越大越糊； $t = T$ 时是纯噪声
β_t	第 t 步的噪声量	预先查表：如从 0.0001 线性涨到 0.02, $T \approx 1000$
$\bar{\alpha}_t = \prod(1 - \beta_s)$	累积信号系数	“还剩多少信号”：从 1 单调降到 ≈ 0
$\epsilon \sim N(0, I)$	标准高斯噪声	每像素独立采样；是训练时已知的“答案”
$\epsilon_\theta(x_t, t)$	去噪网络 (U-Net)	整个扩散模型唯一要学的东西

后面所有公式都只是这六个符号的组合——认住它们，推导就不可怕

单步加噪：缩一点，再添噪声

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t}x_{t-1}, \beta_t \mathbf{I})$$

每一步从 x_{t-1} 得到 x_t : 乘 $\sqrt{1 - \beta_t}$ 略缩, 再叠加方差 β_t 的高斯噪声



信号占比 $\bar{\alpha}_t$ 与噪声占比 $1 - \bar{\alpha}_t$ 的此消彼长 (示意)

- 读法两件事: 旧图像乘 $\sqrt{1 - \beta_t}$ (略缩), 叠加 β_t 方差的噪声
- 为什么乘 $\sqrt{1 - \beta_t}$: 总能量守恒 $(1 - \beta_t) + \beta_t = 1$, 方差不会逐步爆炸
- β_t 是查表值, 无任何学习参数; $T \approx 1000$ 步后 $x_T \approx N(0, I)$

闭式解与重参数化：训练样本的免费发生器

$$\alpha_t = 1 - \beta_t, \bar{\alpha}_t = \prod_{s=1}^t \alpha_s, q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

② 高斯可连乘合并：任意 t 的 x_t 直接由 x_0 与 $\bar{\alpha}_t$ 决定，不必逐步走链

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

③ 重参数化：把 ② 解出来——干净图×系数 + 噪声×系数

- 数值感受： $\bar{\alpha}_t$ 从 1 单调降到 0
- t 小： $\approx$ 原图； $t = T$ ：纯噪声
- 此处出现的 ϵ 正是网络之后要猜的“答案”（伏笔）

随机抽 $(x_0, t, \epsilon) \rightarrow$ 一行代码合成 x_t ：这就是训练数据的“免费发生器”

反向也建模为高斯：只差一个均值要学

$$p_{\theta}(x_{t-1} | x_t) = \mathcal{N}(\mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t))$$

① 反向每步建模为高斯：网络参数化其均值与方差

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(\tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t \mathbf{I})$$

② 数学事实：若额外知道 x_0 ，真实反向分布（后验）有闭式

- DDPM 结论：方差可直接固定 $\sigma_t^2 = \beta_t$ ，不必学
- 后验方差 $\tilde{\beta}_t = \beta_t(1 - \bar{\alpha}_{t-1})/(1 - \bar{\alpha}_t)$ 也是已知量
- 于是“学反向” = “学均值”，且均值能写成 ϵ 的函数（下一页）

于是「学反向」坍缩为「学均值」——而均值恰好可以由 ϵ 表达（下一页）

核心一步：均值完全由噪声表达

$$x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon}{\sqrt{\bar{\alpha}_t}}$$

① 从重参数化公式反解 x_0

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right)$$

② 代入后验：真实均值只剩 ϵ 一个未知量

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right)$$

③ 网络均值：把 ϵ 换成估计 ϵ_θ —— 唯一可学的部件

$\epsilon_\theta(x_t, t)$

整个扩散模型唯一要学的东西：看一张模糊图，猜上面的噪声

- 均值的结构：把估出的噪声从 x_t 里减掉，再缩放
- 训练学 ϵ_θ ；采样时按 μ_θ 公式走一步

从 ELBO 到 ϵ -预测：三步化简

$$L_{ELBO} = L_0 + \sum_{t=2}^T L_{t-1} + L_T$$

① 变分下界：先验项 L_T (无参数) + 各去噪步 L_{t-1} + 重建项 L_0 (常忽略)

$$L_{t-1} = D_{KL}(q(x_{t-1} | x_t, x_0) \| p_{\theta}(x_{t-1} | x_t))$$

② 每个去噪步 = 两个固定方差高斯的 KL → 有闭式

$$L_{simple} = \mathbb{E}_{x_0, \epsilon \sim \mathcal{N}(0, I), t} [\|\epsilon - \epsilon_{\theta}(x_t, t)\|_2^2]$$

③ 把 μ_{θ} 代入化简 → 简化目标：MSE 猜噪声

- L_T 无参数、 L_0 常忽略 → 学习压力全部落在去噪步
- KL 闭式 = 均值之差 × 系数；代入 μ_{θ} 后只剩 $\epsilon - \epsilon_{\theta}$
- 为什么预测 ϵ 而非 x_0 ： ϵ 对所有 t 统计相同，损失尺度均匀；预测 x_0 则误差随 t 剧烈变化

训练与采样：各五行伪代码

训练（对应式③）

```
repeat
   $x_0 \sim \text{数据集}$ 
   $t \sim \text{Uniform}\{1..T\}$ 
   $\epsilon \sim N(0, I)$ 
   $x_t = \sqrt{\bar{\alpha}_t} \cdot x_0 + \sqrt{(1-\bar{\alpha}_t)} \cdot \epsilon$ 
  梯度下降  $\|\epsilon - \epsilon_\theta(x_t, t)\|^2$ 
until 收敛
```

采样（生成一张图）

```
 $x_T \sim N(0, I)$ 
for  $t = T, \dots, 1$ :
   $z \sim N(0, I)$  ( $t > 1$ )
   $x_{t-1} = \mu_\theta(x_t, t) + \sigma_t \cdot z$ 
return  $x_0$ 
```

DDIM：把采样改成确定性、可跳步的版本 → 20–50 步即可出图（LDM 默认）

去噪网络 U-Net: 细节与语义的立交桥



- 编码器压缩到低分辨率（语义），解码器逐级还原（细节）
- 跳跃连接：同层特征直通解码端——保细节 + 缓解梯度消失
- 组件：残差块 + GroupNorm + SiLU；低分辨率层加 self-attention
- 时间步 t ：正弦位置嵌入投影进每个残差块（一个网络管所有噪声水平）
- U-Net 2015 年提出，扩散模型让它成为生成领域的事实标准骨干

扩散这么好——但像素空间训练与推理都贵得离谱

150–1000

V100·天 —— 训练一个 SOTA 像素扩散模型 (ADM) 的典型开销

≈ 5 天

单张 A100 上生成 5 万张图 (推理顺序评估的代价)

25–1000 步

采样需顺序执行去噪网络, 步间无法并行

- 根因: 高维 RGB 空间 ($512 \times 512 \times 3 \approx 78.6$ 万维) 里反复评估同一个大网络
- 后果一: 只有少数机构训得动, 学术圈难以参与, 碳 footprint 巨大
- 后果二: 推理慢 → 实际部署 (如医学影像 workflow) 不可行

通往高分辨率生成：三条已有路线的困境

① GAN 路线

- 对抗训练难以覆盖复杂多模态分布
- 模式坍缩、多样性(recall)差
- 可控性依赖额外注入设计，无统一条件接口

② VQGAN + 自回归 Transformer (DALL·E)

- 为迁就 Transformer 激进下采样 ($f \geq 16$)
- 重建上界受损，纹理细节失真
- 放弃 2D 归纳偏置，全局注意力昂贵

③ 级联扩散 CDM (多模型串联)

- 基础模型 $64^2 \rightarrow$ 多级超分扩散到 256^2+
- 多模型串行：训练管线与误差累积
- 条件增强等技巧进一步推高复杂度

LDM 选择第四条路：不换架构、不串联模型——把整个扩散过程搬进自编码器的潜空间

三大生成模型对比：各自的位置

模型	生成机制	训练方式	优点	局限
GAN	生成器 vs 判别器博弈	min-max 对抗	单步采样快、图像锐利	模式坍缩、训练不稳、多样性差
VAE	编码分布 + 重参数化解码	ELBO 最大化	潜空间规整、训练稳定	生成偏模糊，单模型质量有限
扩散	逐步加噪 → 学习去噪	去噪 MSE (ELBO 简化)	多样性好、训练稳、引导灵活	迭代采样慢、算力需求高

注意：VAE 并没有退场——它以“感知压缩模块”的身份成为 LDM 的第一阶段（本文伏笔）

- 扩散的“慢”有成熟补救：DDIM 少步采样、蒸馏、LCM 等（本文即用 DDIM）

把图像生成分解为两个子问题

图像生成


=

感知压缩 (去冗余)

+

语义生成 (对内容建模)

- 数字图像的大部分比特编码感知上不可见的细节 (高频纹理)
- 感知压缩交给自编码器: 一次前向即可恢复像素级细节
- 语义生成交给扩散模型: 只在压缩后的潜空间建模数据分布
- 两个阶段解耦 → 各自用最合适的技术, 算力花在刀刃上



论文图 2: 感知压缩 vs 语义压缩示意

压缩越激进，重建上界损失越大



论文图 1: DIV2K 512² 上不同 f 的重建对比

第一阶段	f	PSNR ↑	R-FID ↓
ours (LDM)	4	27.4	0.58
DALL-E 所用	8	22.8	32.01
VQGAN	16	19.9	4.98

- f=4: 重建几乎无损 (R-FID 0.58) , 细节全保留
- f=8/f=16: 纹理明显退化——这是 AR 路线的固有代价
- 扩散不需要激进压缩 → 可以用轻压缩换高上界

02

方法：两阶段潜空间扩散

第一阶段感知压缩（自编码器） + 第二阶段语义生成（潜空间 DDPM）

两阶段流水线：扩散只发生在潜空间



感知压缩自编码器：四项损失各司其职

$$\mathcal{L}_{Autoencoder} = \mathcal{L}_{rec} + \lambda_{perc} \mathcal{L}_{perceptual} + \lambda_{adv} \mathcal{L}_{adv} + \lambda_{reg} \mathcal{L}_{reg}$$

L_rec (L1 像素重建)

管全局结构与灰度一致性

L_perceptual (VGG 特征匹配)

管“看起来像不像”——在感知空间比对齐像素更重要

L_adv (PatchGAN 对抗)

管“锐不锐”——判别器只看局部 patch，逼出高频纹理

L_reg (潜空间正则)

管潜空间的“形状” (下一页)

为什么不能只用 L2?

回归的最优解 = 所有可能图像的平均 → 平均必然模糊。感知项补“像”，对抗项补“锐”，三项合起来才有又像又锐的重建。

这一阶段的重建质量 = LDM 生成质量的硬上界；对我们的 CT: HU 定量精度也由它决定。

潜空间正则：KL 还是 VQ？轻重要拿捏

KL 正则（连续潜空间）

- 对 $q(z|x)$ 施加轻微 KL 惩罚，拉向 $N(0, I)$
- 连续潜空间；Stable Diffusion (KL-8) 即此路线
- 重建略好于 VQ 版（论文 Tab. 8）

VQ 正则（离散码本）

- 解码器内置向量量化码本（量化层被解码器吸收）
- 论文主实验默认：采样质量优于 KL 版
- 训练用直通梯度估计量化处的梯度

$$\mathcal{L}_{reg}^{KL} = D_{KL}(q(z|x) \parallel \mathcal{N}(0, I)), w_{KL} \ll 1$$

KL 正则项（权重 $\ll 1$ ）：只防潜空间任意高方差，不追求严格先验

拿捏的关键：潜空间“略微发散”反而对扩散友好——所有样本挤在细流形上，加噪去噪反而没有施展空间

潜空间扩散：与 DDPM 逐符号对照

$$\mathcal{L}_{LDM} = \mathbb{E}_{\mathcal{E}(x), \epsilon \sim \mathcal{N}(0, \mathbf{I}), t} [\|\epsilon - \epsilon_{\theta}(z_t, t)\|_2^2]$$


48×

维度缩减: $512 \times 512 \times 3 \rightarrow 128 \times 128 \times 4$ ($f=4$)

DDPM (像素空间)	LDM (潜空间)	变化
x_0 (干净图像)	$z_0 = E(x_0)$	换空间
$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{(1 - \bar{\alpha}_t)} \cdot \epsilon$	$z_t = \sqrt{\bar{\alpha}_t} z_0 + \sqrt{(1 - \bar{\alpha}_t)} \cdot \epsilon$	同式
$\epsilon_{\theta}(x_t, t)$ (U-Net)	$\epsilon_{\theta}(z_t, t)$ (同一 U-Net)	同构
噪声调度 / ϵ -目标 / DDIM	噪声调度 / ϵ -目标 / DDIM	完全继承

理论零新增：公式、调度、目标、采样器全部继承——收益全在维度 ($f=4$ 时缩小 48 倍)

压缩率 f : 训练效率与质量上限的权衡



论文图 5: ImageNet 类条件 LDM 不同 f 的训练曲线 (2M 步, 同一 A100 预算)

FID gap = 38

LDM-1 (像素级) vs LDM-8, 2M 步后


$f \in [4, 16]$

甜点区: LDM-4/8 最优

LDM-32 X

过压缩: 第一阶段重建损失成瓶颈

速度-质量权衡：LDM-4/8 全面占优



论文图 6: CelebA-HQ (左) / ImageNet (右), DDIM 步数 {10,20,50,100,200} 从右向左


- 横轴 V100 上每张图采样耗时, 纵轴 FID (5000 样本评估)
- LDM-{4-8} 在同等质量下比高压压缩/低压压缩版本都快
- 低步数 (20-50 步 DDIM) 即可接近最优质量 → 实用性关键

03

条件机制与引导

拼接 / Cross-Attention / Classifier-Free Guidance —— 本文方法上最大的贡献

两类条件注入：空间拼接 与 交叉注意力



论文图 3：上=拼接式条件化；下=cross-attention 条件化


拼接 (concatenation)

空间对齐条件：语义图 / 低分辨率图 / 掩码+图像。降采样到潜分辨率后沿通道维拼给 UNet

Cross-attention

任意模态条件：文本 / 类别 / 布局框 / 参数向量。经 τ_θ 编码成 token 序列注入

拼接式：为空间对齐条件保留卷积本性



- 适用任务：语义合成 (landscape)、超分辨率 (低分图上采样后拼接)、修复 (掩码+已知图像拼接)
- 关键优势：不改网络空间结构 $\rightarrow$ 保留平移等变性
- 卷积式采样： 256^2 训练的模型可滑窗外推到 512×1024 (实验部分展示)

Cross-attention: 任意模态条件的通用接口

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) \cdot V$$

$$Q = W_Q^{(i)} \cdot \varphi_i(z_t), K = W_K^{(i)} \cdot \tau_\theta(y), V = W_V^{(i)} \cdot \tau_\theta(y)$$

$Q \leftarrow \varphi_i(z_t)$

UNet 第 i 层特征展平为 N 个空间 token

$K, V \leftarrow \tau_\theta(y)$

条件编码为 M 个 token (可变长)

输出

以残差形式并回 UNet 主干

训练

τ_θ 与 ε_θ 联合端到端优化

- 直觉: 每个空间位置 (Q) 自行决定 “看条件的哪一段” (K/V)
- τ_θ 是领域专家, 可插拔: 文本=Transformer (CLIP), 布局=小CNN
- 条件注入与主干解耦 → 多条件融合的天然容器

通用接口

后续 SD 的 text cross-attention 即由此而来

走一遍：一条文本如何指挥每个像素



提问 → 应答

Q: 图像空间位置在问; K/V: 条件 token 在答

- 换条件 = 换 τ_θ : 文本=CLIP、布局=小 CNN、参数向量=MLP
- 主干 U-Net 不需任何结构改动

我们的六轴条件 (mAs/视角/弧段/r/SOD/SDD) 同理: 每轴一个 token, τ_θ 用小 MLP/Transformer 即可接入

条件 LDM: τ_θ 与 ϵ_θ 联合优化

$$\mathcal{L}_{LDM} := \mathbb{E}_{\mathcal{E}(x), y, \epsilon \sim \mathcal{N}(0, \mathbf{I}), t} [\|\epsilon - \epsilon_\theta(z_t, t, \tau_\theta(y))\|_2^2]$$


- 式(3)在式 $\mathcal{L}_{LDM}$ 基础上多了条件路径 $\tau_\theta(y)$, 期望同时遍历 $(\mathcal{E}(x), y)$ 配对
- τ_θ 与去噪网络 ϵ_θ 一起反向传播、联合收敛
- y 可以是文本、类别、布局, 也可以是参数向量 —— 接口统一

对应我们课题: 六轴条件向量 (mAs, 视角数, 弧段, r, SOD, SDD) + 源图像 → 就是 y 的两种实例

Classifier-Free Guidance: 免分类器的条件强化

$$\tilde{\epsilon}_{\theta}(z_t, c) = \epsilon_{\theta}(z_t, \emptyset) + w \cdot [\epsilon_{\theta}(z_t, c) - \epsilon_{\theta}(z_t, \emptyset)]$$

- 训练: 以一定概率 (如 10%) 把条件替换为空条件 $\emptyset \rightarrow$ 同一网络兼任无条件模型
- 采样: 沿“条件方向”外推, w 控制遵从度
- $w = 1$ 退化为普通条件采样; $w \uparrow$ 条件遵从 $\uparrow$ 、样本质量 $\uparrow$ 、多样性 $\downarrow$
- 无需分类器 (对比 classifier guidance), 对任意条件类型通用



10.56 $\rightarrow$ 3.60

类条件 ImageNet FID ($w=1.5$)

23.35 $\rightarrow$ 12.61

文本条件 COCO FID ($w=1.5$)

04

实验结果

五类任务、两图两表：只讲支撑设计决策的关键数字

无条件生成：与 GAN 系高度竞争




论文图 4: CelebA-HQ / FFHQ / LSUN-Churches / LSUN-Bedrooms / ImageNet 256² 生成样例

数据集	最佳 GAN 系	LDM	读数
CelebA-HQ 256 ²	ProjectedGAN 3.08	LDM-4	FID 4.98
FFHQ 256 ²	ADM 1.90	LDM-8 (KL)	FID 4.02
LSUN-Churches	ProjectedGAN 1.59	LDM-4	FID 2.95

- FID 仍落后顶级 GAN，但 recall（多样性）普遍更好
- 200 步 DDIM 即达最优 FID

类条件 ImageNet: 以更少参数刷新 SOTA




ImageNet 256² 类条件生成, FID ↓ (越低越好)

- LDM-4-G (CFG $w=1.5$) FID 3.60, 超过 ADM-G 的 4.59 —— 新 SOTA
- 参数量 400M vs ADM-G 608M
- IS 247.7 (ADM-G 186.7) ; Precision 0.87
- 无 CFG 时 (10.56) 与 ADM (10.94) 持平 → 收益主要来自 CFG

400M 参数

完成 608M 模型未及的质量 (250 DDIM 步)

文本到图像：COCO 零样本大幅领先（当年）



MS-COCO 验证集零样本文本到图像，FID ↓ (250 DDIM 步)

- τ_θ = CLIP 文本 Transformer (领域专家实例)
- 无引导已领先 AR/GAN 路线 (23.35 vs ~27)
- CFG ($w=1.5$) 再近乎减半 → 12.61, IS 26.6
- cross-attention 的伸缩性首次在文本模态上验证

12.61

LDM-KL-8 + CFG 的 COCO FID (DALL-E 为 27.50)

卷积式采样：256² 训练 → 512×1024 推理



- 拼接式条件不改变网络的空间结构 → UNet 是纯卷积滑窗可用的
- 论文图 8：语义合成 (landscape) 任务上直接外推 4 倍像素
- 全局 attention 的 AR 路线 (DALL·E) 做不到——注意力模式绑定训练分辨率
- 对我们的意义：CT/MRI 不同矩阵尺寸/FOV 的泛化可能性

超分辨率与图像修复：像素级任务的落地

超分辨率 ($\times 4$, ImageNet 256^2)

- 条件 = 上采样后的低分图, 与 z_t 通道拼接
- LDM-SR 纹理真实感优于 SR3; 精细重复结构不如 SR3
- big 版 552M、100 步: FID 2.4[†], A100 上 4.5 s/图
- 引导版 184M、50 步: 0.38 s/图 (快 12 倍, 质量略降)

图像修复 (CelebA-HQ / Places2)

- 条件 = 掩码 + 已知图像拼接; 采样每步做潜层融合 (已知区域保持 noised 版本)
- big + 微调 (387M) : 40–50% 掩码下 FID 9.39
- 用户研究整体优于 LaMa (纯判别式修复)
- 组合式场景合成: 多对象布局 $\rightarrow$ cross-attention 的功劳

局限：LDM 没解决的问题

- 两阶段非端到端：第一阶段重建误差是生成质量的硬上界，E/D 无法感知下游需求
- 潜空间正则的取舍（KL vs VQ、权重多大）仍是经验权衡，无理论指导
- 文本理解完全依赖冻结的 CLIP——语义能力受制于外部模型
- 高频细节全交给解码器：极端压缩 ($f \geq 32$) 下细节失真
- 采样仍是多步迭代（相比 GAN 单步），实时性依赖蒸馏等后处理

上界效应

对我们：CT 的 HU 定量精度直接受 VAE 重建上界约束（HU MAE 评估必做）

正则权衡

对我们：医学影像潜空间统计与自然图像不同，KL 权重需重调

从论文到生态：Stable Diffusion 的起点

39,000+

被引 (截至 2026 年)

SD 1.x / 2.x

Stable Diffusion 直接基于 LDM-KL-8 架构

diffusers

AutoencoderKL + UNet2DConditionModel
即本文两阶段

2021.12 arXiv v1



2022.06 CVPR 发表



2022.08 Stable Diffusion 开源



2023+ 生态: SDXL /
ControlNet / 医学 LDM


- 方法论遗产: 两阶段解耦 + cross-attention 条件接口, 成为后续所有文生图模型的标配

05

对我们课题的启发

条件 LDM 原型的三个设计决策：架构复刻 / 条件注入选型 / CT 特殊性

主模型直接对标：实验路线照 LDM 复刻



- 顺序 1：单独训练并冻结 VAE —— 验收标准加 CT 特有指标 (HU MAE / 结构 SSIM)
- 顺序 2：潜空间条件 UNet —— 六轴条件经 τ_θ 注入
- 顺序 3：复刻论文图 5 的压缩率消融 ($f=2/4/8$)，CT 上重找甜点区
- 已有基础：小复刻已验证“条件差向量驱动转换” (test PSNR 22.30 vs 16.33, +6dB) ——那是像素级；LDM 是下一步

六轴条件的注入选型：三条路线对照

注入方式	适配条件类型	优点	注意
拼接 concat (本文)	空间对齐：源图像潜变量	保留平移等变、可外推分辨率	只吃张量型条件
Cross-attention (本文)	任意 token：六轴参数、文本	通用可插拔、多条件容器	标量条件略绕（先成 token）
FiLM 调制 (论文5 PDF)	标量参数：几何/剂量	逐通道仿射、极轻量	表达力弱于注意力

初步方案：源图像 → 拼接；六轴向量 → cross-attention（每轴一个 token）；FiLM 作对照实验

- 与上次汇报的论文5（PDF/FiLM）正好构成两条注入路线的对照——组会可请老师给意见

CT 的特殊性与未见条件组合泛化

f 的选择：CT 比自然图像更保守

- CT 是定量成像：HU 误差直接传导诊断信息
- 细微结构（骨小梁、小病灶）对重建敏感 $\rightarrow f=4$ 甚至 2 起步
- 潜空间统计与自然图像不同：KL 权重需在 CT 上重调
- 验收指标：HU MAE / RMSE + 器官分割一致性

未见条件组合泛化 $\leftrightarrow$ CFG 思想

- CFG 本质：沿“条件方向”差值外推 ($\epsilon_c - \epsilon_\emptyset$)
- 与我们小复刻的“条件差向量”假设同构
- 训练时对六轴条件做 5–10% 随机 dropout，保留无条件分支
- 推理时可调 w：条件遵从度 vs 多样性的旋钮

五句话带走 LDM

解耦

图像生成 = 感知压缩（自编码器）+ 语义生成（潜空间扩散），算力降 1-2 个数量级

甜点区

$f \in [4, 16]$: 压缩不足太贵、过压缩伤上界（ImageNet 消融 FID gap 38）

条件接口

拼接管空间对齐条件；cross-attention 管任意模态—— τ_θ 可插拔是多条件系统的关键

CFG

随机丢条件 + 采样差值外推：类条件 10.56→3.60、文本 23.35→12.61

统一框架

一个 LDM 覆盖无条件/类/文本/布局/超分/修复，后两者当时 SOTA

谢谢聆听 · 欢迎讨论

两个想请大家给意见的问题：

- ① 六轴标量条件用 cross-attention 还是 FiLM 调制更合适？
- ② CT 的第一阶段 VAE，重建验收除 PSNR/SSIM 外如何定 HU 定量标准？

论文：arXiv 2112.10752 · DOI 10.1109/CVPR52688.2022.01042 · 代码 github.com/CompVis/latent-diffusion

笔记：[[论文6：高分辨率图像合成与潜空间扩散模型（LDM）]] · 汇报人：潘耀辉