

组会论文汇报 · 2026-09-20

高分辨率图像合成 与潜空间扩散模型


High-Resolution Image Synthesis with Latent Diffusion Models

Robin Rombach*, Andreas Blattmann*, Dominik Lorenz, Patrick Esser, Björn Ommer

LMU Munich & Heidelberg University · Runway ML · CVPR 2022

arXiv 2112.10752 · Stable Diffusion 底座论文

汇报人：潘耀辉



论文图 3：LDM 条件注入机制（拼接 / cross-attention）

汇报大纲

01

背景与动机

像素空间扩散为什么贵；已有路线缺什么

03

条件机制与引导

拼接 / Cross-Attention / Classifier-Free Guidance

05

对我们课题的启发

条件 LDM 原型的三个设计决策

02

方法：两阶段潜空间扩散

感知压缩自编码器 + 潜空间 DDPM

04

实验结果

压缩率消融与五类任务的定量结论

06

总结与讨论

要点回顾 + 两个待讨论问题

01

背景与动机

像素空间扩散的算力困境，与“压缩”的正确打开方式

扩散模型 60 秒回顾（衔接已读论文）

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

前向过程：任意 x_0 经固定噪声调度直接得到 x_t （闭式）

$$L_{\text{simple}} = \mathbb{E}_{x_0, \varepsilon \sim \mathcal{N}(0, \mathbf{I}), t} [\|\varepsilon - \varepsilon_{\theta}(x_t, t)\|_2^2]$$

简化训练目标：预测加入的噪声 ε （DDPM, Ho et al. 2020）

- 前向加噪无学习参数，反向过程由 ε_{θ} 逐步去噪
- ε - 预测参数化 + 简化目标 $\rightarrow$ 训练稳定，是 DDPM 的核心贡献
- Score-SDE（已读论文 2）把它推广到连续时间：条件生成即对 $p(z|y)$ 建模

扩散模型 = 顺序去噪的自编码器栈：一切开销都来自“每一步都要跑一遍大网络”

像素空间扩散：训练与推理都贵得离谱

150–1000

V100·天 —— 训练一个 SOTA 像素扩散模型（ADM）的典型开销

≈ 5 天

单张 A100 上生成 5 万张图（推理顺序评估的代价）

25–1000 步

采样需顺序执行去噪网络，步间无法并行

- 根因：高维 RGB 空间（ $512 \times 512 \times 3 \approx 78.6$ 万维）里反复评估同一个大网络
- 后果一：只有少数机构训得动，学术圈难以参与，碳 footprint 巨大
- 后果二：推理慢 → 实际部署（如医学影像工作流）不可行

已有的“潜空间”路线为什么不够

GAN 路线

- 优点：单步采样、视觉锐利

- 对抗训练难以扩展到复杂多模态分布

模式坍塌，多样性 (recall) 普遍差

- 可控性依赖额外条件注入设计

没有统一的条件接口

VQGAN + 自回归 Transformer (DALL·E 路线)

- 潜空间 + 强语言先验，可行

- 为迁就 Transformer 必须激进下采样

$f=16$ 甚至 $64 \rightarrow$ 重建上界受损，细节失真

- 放弃图像的 2D 归纳偏置

全局 attention 昂贵，难外推分辨率

需要的是：适度压缩、对卷积友好的连续潜空间 + 通用条件接口 —— 这就是 LDM 的设计目标

把图像生成分解为两个子问题

图像生成


=

感知压缩 (去冗余)

+

语义生成 (对内容建模)

- 数字图像的大部分比特编码感知上不可见的细节 (高频纹理)
- 感知压缩交给自编码器: 一次前向即可恢复像素级细节
- 语义生成交给扩散模型: 只在压缩后的潜空间建模数据分布
- 两个阶段解耦 → 各自用最合适的技术, 算力花在刀刃上



论文图 2：感知压缩 vs 语义压缩示意

压缩越激进，重建上界损失越大

论文图 1：DIV2K 512² 上不同 f 的重建对比

第一阶段	f	PSNR ↑	R-FID ↓
ours (LDM)	4	27.4	0.58
DALL-E 所用	8	22.8	32.01
VQGAN	16	19.9	4.98

- $f=4$ ：重建几乎无损（R-FID 0.58），细节全保留
- $f=8/f=16$ ：纹理明显退化——这是 AR 路线的固有代价
- 扩散不需要激进压缩 → 可以用轻压缩换高上界

02

方法：两阶段潜空间扩散

第一阶段感知压缩（自编码器） + 第二阶段语义生成（潜空间 DDPM）

两阶段流水线：扩散只发生在潜空间



感知压缩自编码器：损失设计与潜空间正则

$$\mathcal{L}_{\text{Autoencoder}} = \mathcal{L}_{\text{rec}} + \lambda_{\text{perc}} \mathcal{L}_{\text{perceptual}} + \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} + \lambda_{\text{reg}} \mathcal{L}_{\text{reg}}$$

- | | |
|--------------------------------|------------------------|
| L_rec (L1 像素重建) | 保全局结构与灰度 / 颜色一致性 |
| L_perceptual (VGG 特征匹配) | 感知相似而非逐像素相同, 避免过度模糊 |
| L_adv (PatchGAN 对抗) | 逼出照片级锐度与真实纹理 |
| L_reg (潜空间正则) | 防潜空间任意高方差, 方便扩散建模 (见下) |

KL 正则 (连续潜空间)

- 轻微 KL 惩罚拉向 $N(0, I)$, 权重 $\ll 1$
- 可控生成路线主流 (Stable Diffusion 即 KL-8)

VQ 正则 (离散码本)

- 解码器内置向量量化层 ($\approx$ VQGAN, 量化被解码器吸收)
- 论文主实验默认: 采样质量优于 KL 版


潜空间扩散：目标函数与 DDPM 完全同构

$$\mathcal{L}_{LDM} = \mathbb{E}_{\mathcal{E}(x), \varepsilon \sim \mathcal{N}(0, \mathbf{I}), t} [\|\varepsilon - \varepsilon_{\theta}(z_t, t)\|_2^2]$$

与 DDPM 唯一的区别：

把 x 换成 $z = E(x)$ ，其余（噪声调度、 ε -预测、采样器）全部继承

- 期望下标 $E(x)$ ：采样自冻结编码器输出的潜变量分布
- UNet：2D 卷积残差块 + GroupNorm + SiLU
- 多分辨率层级插入 self-attention（继承 ADM 实践）
- 时间步 t ：正弦位置嵌入 → 投影进各残差块
- big 变体：注意力三层级 + BigGAN 残差块上下采样，387M 参数
- 第一阶段可去 attention：VQ-LDM-4 降低高分辨率解码显存
- 采样器以 DDIM 为主（少步数、确定性）



论文图 4（节选视角）：潜空间扩散的生成样例


卷积友好

潜空间保留 2D 结构 → 可滑窗外推分辨率（见实验）

215M / 387M

UNet 参数量：标准版 / big 版

压缩率 f ：训练效率与质量上限的权衡



论文图 5：ImageNet 类条件 LDM 不同 f 的训练曲线（2M 步，同一 A100 预算）

FID gap = 38

LDM-1（像素级）vs LDM-8，2M 步后


$f \in [4, 16]$

甜点区：LDM-4/8 最优

LDM-32 $\times$

过压缩：第一阶段重建损失成瓶颈

速度 - 质量权衡： LDM-4/8 全面占优



论文图 6： CelebA-HQ (左) / ImageNet (右) ， DDIM 步数 {10,20,50,100,200} 从右向左


- 横轴 V100 上每张图采样耗时，纵轴 FID (5000 样本评估)
- LDM-{4-8} 在同等质量下比高压压缩 / 低压压缩版本都快
- 低步数 (20-50 步 DDIM) 即可接近最优质量 → 实用性关键

03

条件机制与引导

拼接 / Cross-Attention / Classifier-Free Guidance —— 本文方法
上最大的贡献

两类条件注入：空间拼接 与 交叉注意力



论文图 3：上 = 拼接式条件化；下 = cross-attention 条件化


拼接 (concatenation)

空间对齐条件：语义图 / 低分辨率图 / 掩码 + 图像。降采样到潜分辨率后沿通道维拼给 UNet

Cross-attention

任意模态条件：文本 / 类别 / 布局框 / 参数向量。经 τ_θ 编码成 token 序列注入

拼接式：为空间对齐条件保留卷积本性



- 适用任务：语义合成（landscape）、超分辨率（低分图上采样后拼接）、修复（掩码 + 已知图像拼接）
- 关键优势：不改网络空间结构 → 保留平移等变性
- 卷积式采样：256² 训练的模型可滑窗外推到 512×1024（实验部分展示）

Cross-attention : 任意模态条件的通用接口

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) \cdot V$$

$$Q = W_Q^{(i)} \cdot \varphi_i(z_t), \quad K = W_K^{(i)} \cdot \tau_\theta(y), \quad V = W_V^{(i)} \cdot \tau_\theta(y)$$

$Q \leftarrow \varphi_i(z_t)$

UNet 第 i 层特征展平为 N 个空间 token

$K, V \leftarrow \tau_\theta(y)$

条件编码为 M 个 token (可变长)

输出

以残差形式并回 UNet 主干

训练

τ_θ 与 ε_θ 联合端到端优化

- 直觉: 每个空间位置 (Q) 自行决定 “看条件的哪一段” (K/V)
- τ_θ 是领域专家, 可插拔: 文本 = Transformer (CLIP), 布局 = 小 CNN
- 条件注入与主干解耦 $\rightarrow$ 多条件融合的天然容器

通用接口

后续 SD 的 text cross-attention 即由此而来

条件 LDM : τ_θ 与 ε_θ 联合优化

$$\mathcal{L}_{LDM} := \mathbb{E}_{\mathcal{E}(x), y, \varepsilon \sim \mathcal{N}(0, \mathbf{I}), t} [\|\varepsilon - \varepsilon_\theta(z_t, t, \tau_\theta(y))\|_2^2]$$


- 式 (3) 在式 $\mathcal{L}_{LDM}$ 基础上多了条件路径 $\tau_\theta(y)$, 期望同时遍历 $(\mathcal{E}(x), y)$ 配对
- τ_θ 与去噪网络 ε_θ 一起反向传播、联合收敛
- y 可以是文本、类别、布局, 也可以是参数向量 —— 接口统一

对应我们课题: 六轴条件向量 (mAs, 视角数, 弧段, r, SOD, SDD) + 源图像 $\rightarrow$ 就是 y 的两种实例

Classifier-Free Guidance : 免分类器的条件强化

$$\tilde{\epsilon}_{\theta}(z_t, c) = \epsilon_{\theta}(z_t, \emptyset) + w \cdot [\epsilon_{\theta}(z_t, c) - \epsilon_{\theta}(z_t, \emptyset)]$$

- 训练: 以一定概率 (如 10%) 把条件替换为空条件 $\emptyset \rightarrow$ 同一网络兼任无条件模型
- 采样: 沿 “条件方向” 外推, w 控制遵从度
- $w = 1$ 退化为普通条件采样; $w \uparrow$ 条件遵从 $\uparrow$ 、样本质量 $\uparrow$ 、多样性 $\downarrow$
- 无需分类器 (对比 classifier guidance) , 对任意条件类型通用



10.56 $\rightarrow$ 3.60

类条件 ImageNet FID ($w=1.5$)

23.35 $\rightarrow$ 12.61


文本条件 COCO FID ($w=1.5$)

04

实验结果

五类任务、两图两表：只讲支撑设计决策的关键数字

无条件生成：与 GAN 系高度竞争




论文图 4：CelebA-HQ / FFHQ / LSUN-Churches / LSUN-Bedrooms / ImageNet 256² 生成样例

数据集	最佳 GAN 系	LDM	读数
CelebA-HQ 256 ²	ProjectedGAN 3.08	LDM-4	FID 4.98
FFHQ 256 ²	ADM 1.90	LDM-8 (KL)	FID 4.02
LSUN-Churches	ProjectedGAN 1.59	LDM-4	FID 2.95

- FID 仍落后顶级 GAN，但 recall（多样性）普遍更好
- 200 步 DDIM 即达最优 FID

类条件 ImageNet：以更少参数刷新 SOTA




ImageNet 256² 类条件生成, FID ↓ (越低越好)

- LDM-4-G (CFG $w=1.5$) FID 3.60, 超过 ADM-G 的 4.59 —— 新 SOTA
- 参数量 400M vs ADM-G 608M
- IS 247.7 (ADM-G 186.7) ; Precision 0.87
- 无 CFG 时 (10.56) 与 ADM (10.94) 持平
→ 收益主要来自 CFG

400M 参数

完成 608M 模型未及的质量 (250 DDIM 步)

文本到图像：COCO 零样本大幅领先（当年）



MS-COCO 验证集零样本文本到图像，FID ↓（250 DDIM 步）

- τ_{θ} = CLIP 文本 Transformer（领域专家实例）
- 无引导已领先 AR/GAN 路线（23.35 vs ~27）
- CFG（ $w=1.5$ ）再近乎减半 → 12.61，IS 26.6
- cross-attention 的伸缩性首次在文本模态上验证

12.61

LDM-KL-8 + CFG 的 COCO FID（DALL-E 为 27.50）

卷积式采样： 256^2 训练 $\rightarrow$ 512×1024 推理



- 拼接式条件不改变网络的空间结构 $\rightarrow$ UNet 是纯卷积滑窗可用的
- 论文图 8：语义合成 (landscape) 任务上直接外推 4 倍像素
- 全局 attention 的 AR 路线 (DALL·E) 做不到——注意力模式绑定训练分辨率
- 对我们的意义：CT/MRI 不同矩阵尺寸 / FOV 的泛化可能性

超分辨率与图像修复：像素级任务的落地

超分辨率 ($\times 4$, ImageNet 256^2)

- 条件 = 上采样后的低分图, 与 z_t 通道拼接
- LDM-SR 纹理真实感优于 SR3 ; 精细重复结构不如 SR3
- big 版 552M、100 步: FID 2.4[†] , A100 上 4.5 s/图
- 引导版 184M、50 步: 0.38 s/图 (快 12 倍, 质量略降)

图像修复 (CelebA-HQ / Places2)

- 条件 = 掩码 + 已知图像拼接; 采样每步做潜层融合 (已知区域保持 noised 版本)
- big + 微调 (387M) : 40–50% 掩码下 FID 9.39
- 用户研究整体优于 LaMa (纯判别式修复)
- 组合式场景合成: 多对象布局 $\rightarrow$ cross-attention 的功劳

局限： LDM 没解决的问题

- 两阶段非端到端：第一阶段重建误差是生成质量的硬上界， E/D 无法感知下游需求
- 潜空间正则的取舍（ KL vs VQ、权重多大）仍是经验权衡，无理论指导
- 文本理解完全依赖冻结的 CLIP——语义能力受制于外部模型
- 高频细节全交给解码器：极端压缩（ $f \geq 32$ ）下细节失真
- 采样仍是多步迭代（相比 GAN 单步），实时性依赖蒸馏等后处理

上界效应

对我们：CT 的 HU 定量精度直接受 VAE 重建上界约束（HU MAE 评估必做）

正则权衡

对我们：医学影像潜空间统计与自然图像不同，KL 权重需重调

从论文到生态：Stable Diffusion 的起点

39,000+

被引 (截至 2026 年)

SD 1.x / 2.x

Stable Diffusion 直接基于 LDM-KL-8 架构

diffusers

AutoencoderKL + UNet2DConditionModel
即本文两阶段

2021.12 arXiv v1



2022.06 CVPR 发表



2022.08 Stable Diffusion 开源



2023+ 生态: SDXL /
ControlNet / 医学 LDM


- 方法论遗产：两阶段解耦 + cross-attention 条件接口，成为后续所有文生图模型的标配

05

对我们课题的启发

条件 LDM 原型的三个设计决策：架构复刻 / 条件注入选型 / CT 特殊性

主模型直接对标：实验路线照 LDM 复刻



- 顺序 1：单独训练并冻结 VAE —— 验收标准加 CT 特有指标（HU MAE / 结构 SSIM）
- 顺序 2：潜空间条件 UNet —— 六轴条件经 τ_θ 注入
- 顺序 3：复刻论文图 5 的压缩率消融（ $f=2/4/8$ ），CT 上重找甜点区
- 已有基础：小复刻已验证“条件差向量驱动转换”（test PSNR 22.30 vs 16.33，+6dB）——那是像素级；LDM 是下一步

六轴条件的注入选型：三条路线对照

注入方式	适配条件类型	优点	注意
拼接 concat（本文）	空间对齐：源图像潜变量	保留平移等变、可外推分辨率	只吃张量型条件
Cross-attention（本文）	任意 token：六轴参数、文本	通用可插拔、多条件容器	标量条件略绕（先成 token）
FiLM 调制（论文 5 PDF）	标量参数：几何 / 剂量	逐通道仿射、极轻量	表达力弱于注意力

初步方案：源图像 → 拼接；六轴向量 → cross-attention（每轴一个 token）；FiLM 作对照实验

- 与上次汇报的论文 5（PDF/FiLM）正好构成两条注入路线的对照——组会可请老师给意见

CT 的特殊性与未见条件组合泛化

f 的选择：CT 比自然图像更保守

- CT 是定量成像：HU 误差直接传导诊断信息
- 细微结构（骨小梁、小病灶）对重建敏感 $\rightarrow f=4$ 甚至 2 起步
- 潜空间统计与自然图像不同：KL 权重需在 CT 上重调
- 验收指标：HU MAE / RMSE + 器官分割一致性

未见条件组合泛化 $\leftrightarrow$ CFG 思想

- CFG 本质：沿 " 条件方向 " 差值外推 ($\epsilon_c - \epsilon_\emptyset$)
- 与我们小复刻的 " 条件差向量 " 假设同构
- 训练时对六轴条件做 5–10% 随机 dropout , 保留无条件分支
- 推理时可调 w : 条件遵从度 vs 多样性的旋钮

五句话带走 LDM

解耦

图像生成 = 感知压缩（自编码器） + 语义生成（潜空间扩散），算力降 1-2 个数量级

甜点区

$f \in [4, 16]$ ：压缩不足太贵、过压缩伤上界（ImageNet 消融 FID gap 38）

条件接口

拼接管空间对齐条件；cross-attention 管任意模态—— τ_θ 可插拔是多条件系统的关键

CFG

随机丢条件 + 采样差值外推：类条件 10.56→3.60、文本 23.35→12.61

统一框架

一个 LDM 覆盖无条件 / 类 / 文本 / 布局 / 超分 / 修复，后两者当时 SOTA

谢谢聆听 · 欢迎讨论

两个想请大家给意见的问题：

- ① 六轴标量条件用 cross-attention 还是 FiLM 调制更合适？
- ② CT 的第一阶段 VAE，重建验收除 PSNR/SSIM 外如何定 HU 定量标准？

论文：arXiv 2112.10752 · DOI 10.1109/CVPR52688.2022.01042 · 代码 github.com/CompVis/latent-diffusion

笔记：[[论文 6：高分辨率图像合成与潜空间扩散模型（LDM）]] · 汇报人：潘耀辉